

Complejidad Económica Provincial

Docente: Nicolas Sidicaro

Alumnos: Nicolas Maidana y José Ignacio Rolón

Ciencia de Datos para Economía y Negocios



INDICE

1. Carga de datos
2. Limpieza de datos
3. Procesamiento de datos
4. Test ANOVA
5. Test de Hipótesis
6. Conclusiones
7. Futuras líneas de investigación



1. Carga de datos

- Importa las bases de **datos originales**.
- **Documenta** la fuente, el nombre y las dimensiones.
- Preparación optimizada dentro el programa. (**Ruteo y tipo de archivo**)

*Garantiza **integridad y trazabilidad** de los datos al inicio del **flujo de trabajo**, aislando los **datos originales** de cualquier modificación posterior.

2. Limpieza de bases

- **Estandarización** de variables (strings y numéricas).
- **Reducción dimensional** no útiles para tratamiento posterior

*Asegura la calidad de los datos, creando un **conjunto de datos estandarizado y optimizado**

3. Análisis Exploratorio de Datos (EDA)

- Base Potencial
- Base Export

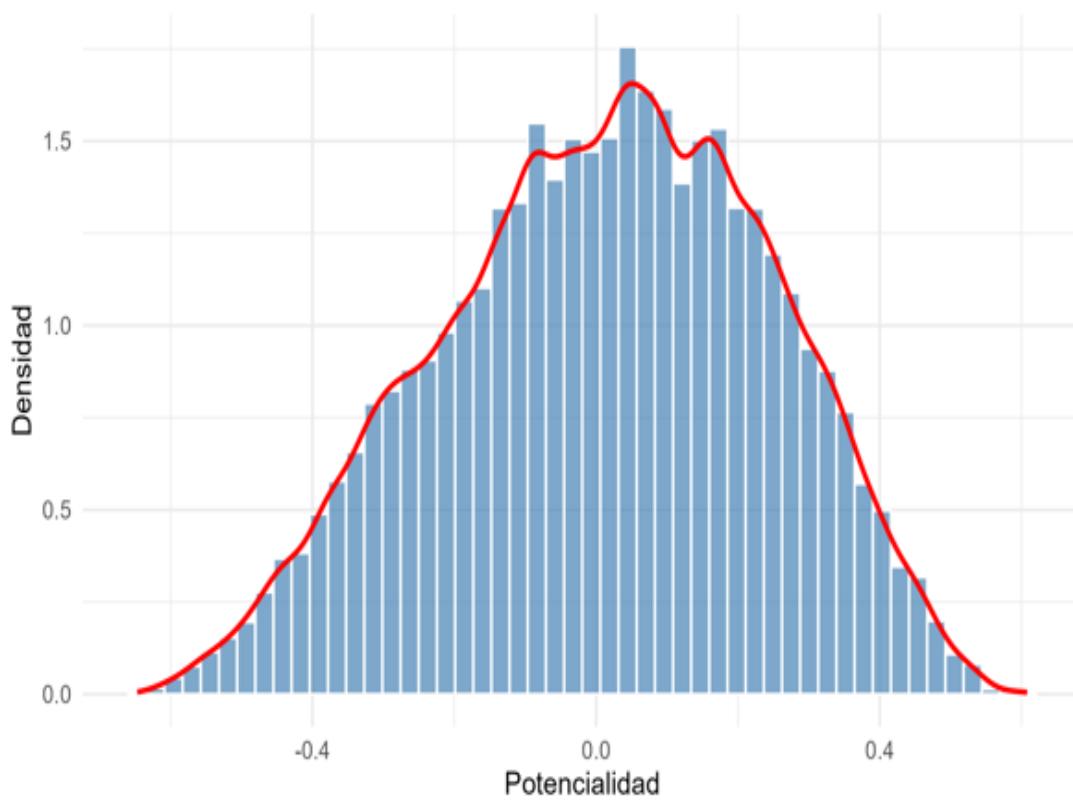
- **Verificación Estructural** sobre datos/variables.
- Manejo de **Datos Faltantes** (NAs): cuantificación y diagnóstico específico.
- **Estadísticas Descriptivas:** métricas clave (**Media**, **Mediana**, Desviación Estándar, IQR, Mín/Máx) para las **variables continuas**.
- **Visualización para Diagnóstico:** boxplots + distribución

***Verifica** la calidad de los **datos**, confirma la necesidad de **manejar la asimetría** y el **rol de los outliers** para nuestras **variables clave**, e identifica el **patrón** de los **NAs**, guiando las **transformaciones** y el **modelado inferencial** subsiguiente.

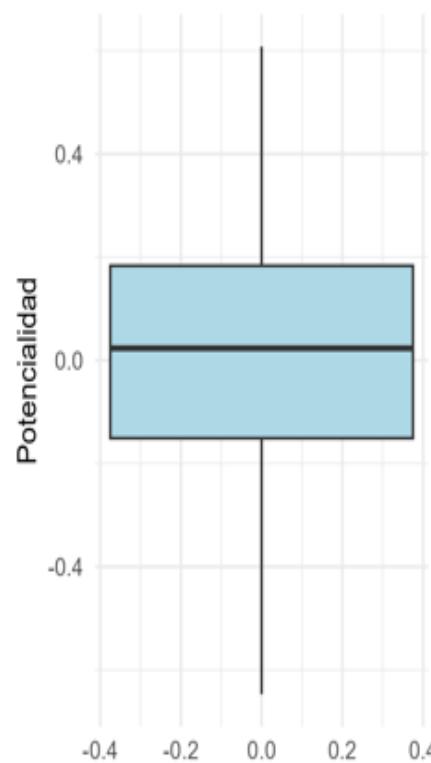
3. Base Pontecialidad (EDA)

Distribución de Potencialidad

Diagnóstico de asimetría para Regresión Híp. C



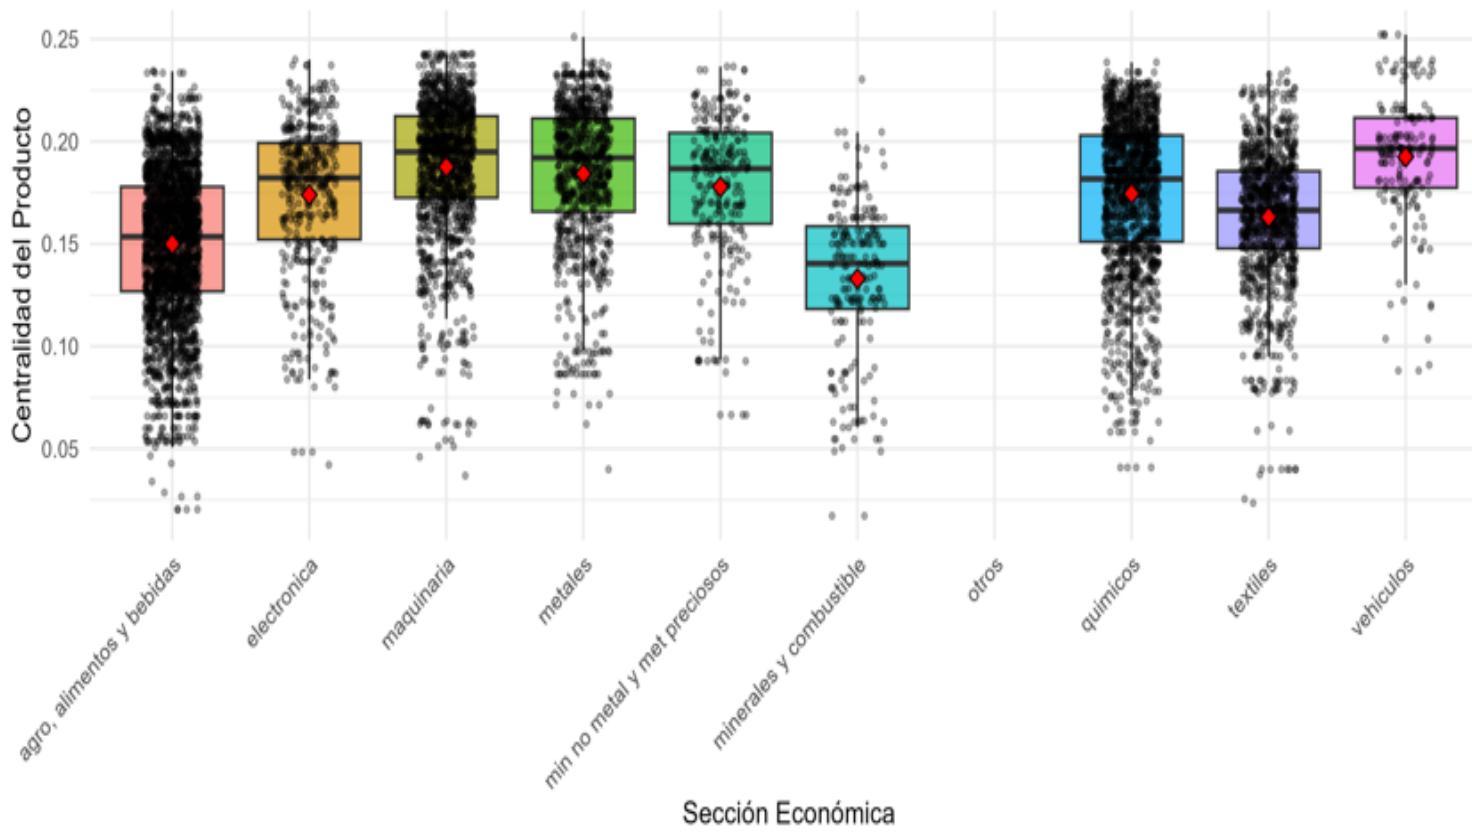
Boxplot de Potencialidad



--- DESCRIPTIVAS CLAVE (BASE_POTENCIAL) ---		
> print(descriptivas_potencial_)	Estadística	valor
1	n	127266.000000000
2	potencialidad_Media	0.010987835
3	potencialidad_Mediana	0.023300000
4	potencialidad_Desvio_Std	0.231137929
5	potencialidad_IQR	0.334300000
6	potencialidad_Min	-0.647100000
7	potencialidad_Max	0.607900000
8	complejidad_producto_Media	0.007711314
9	complejidad_producto_Mediana	0.157700000
10	complejidad_producto_Desvio_Std	0.998865321
11	complejidad_producto_IQR	1.424600000
12	complejidad_producto_Min	-4.657100000
13	complejidad_producto_Max	2.668500000
14	distancia_Media	0.986160829
15	distancia_Mediana	0.991400000
16	distancia_Desvio_Std	0.013739186
17	distancia_IQR	0.014000000
18	distancia_Min	0.801300000
19	distancia_Max	1.000000000
20	fob_mundial_Media	3855235.626321563
21	fob_mundial_Mediana	684275.280000000
22	fob_mundial_Desvio_Std	21432366.394400638
23	fob_mundial_IQR	2133088.700000000
24	fob_mundial_Min	16.110000000
25	fob_mundial_Max	985996987.220000029
26	n_Media	127266.000000000
27	n_Mediana	127266.000000000
28	n_Desvio_Std	NA
29	n_IQR	0.000000000
30	n_Min	127266.000000000
31	n_Max	127266.000000000

3. Base Exportados (EDA)

Centralidad del Producto según Sección Económica
Comparación de medianas y medias (rombo rojo) para ANOVA



--- DESCRIPTIVAS CLAVE (BASE EXPORT) ---		
	Estadistica	valor
1	n	8519.00000000
2	centralidad_Media	0.16833717
3	centralidad_Mediana	0.17430000
4	centralidad_Desvio_Std	0.03940722
5	centralidad_IQR	0.05415000
6	centralidad_Min	0.01720000
7	centralidad_Max	0.25220000
8	complejidad_producto_Media	-0.08527372
9	complejidad_producto_Mediana	0.04970000
10	complejidad_producto_Desvio_Std	0.97142310
11	complejidad_producto_IQR	1.43840000
12	complejidad_producto_Min	-3.85250000
13	complejidad_producto_Max	2.62690000
14	complejidad_provincia_Media	-0.36235559
15	complejidad_provincia_Mediana	-0.33486644
16	complejidad_provincia_Desvio_Std	0.31022827
17	complejidad_provincia_IQR	0.19610411
18	complejidad_provincia_Min	-1.33322010
19	complejidad_provincia_Max	0.08786897
20	n_Media	8519.00000000
21	n_Mediana	8519.00000000
22	n_Desvio_Std	NA
23	n_IQR	0.00000000
24	n_Min	8519.00000000
25	n_Max	8519.00000000

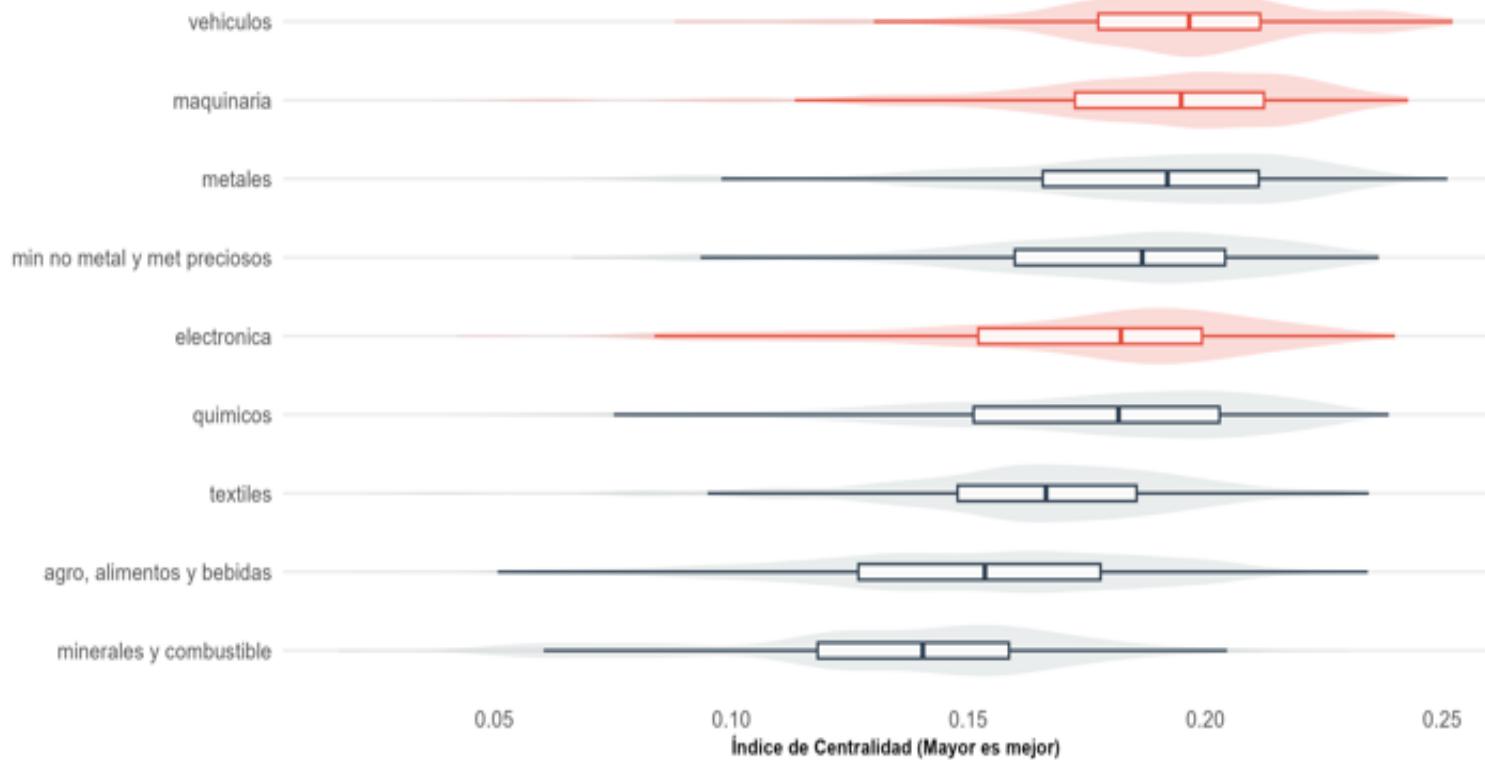
3. Base Exportados (EDA)

Dime qué produces y te diré qué tan conectado estás

Distribución de la Centralidad del Producto según Sector Económico.

Los sectores de alta complejidad técnica dominan el centro del espacio.

Tipo de Sector Complejo Tradicional



--- DESCRIPTIVAS CLAVE (BASE EXPORT) ---

	Estadística	valor
1	n	8519.00000000
2	centralidad_Media	0.16833717
3	centralidad_Mediana	0.17430000
4	centralidad_Desvio_Std	0.03940722
5	centralidad_IQR	0.05415000
6	centralidad_Min	0.01720000
7	centralidad_Max	0.25220000
8	complejidad_producto_Media	-0.08527372
9	complejidad_producto_Mediana	0.04970000
10	complejidad_producto_Desvio_Std	0.97142310
11	complejidad_producto_IQR	1.43840000
12	complejidad_producto_Min	-3.85250000
13	complejidad_producto_Max	2.62690000
14	complejidad_provincia_Media	-0.36235559
15	complejidad_provincia_Mediana	-0.33486644
16	complejidad_provincia_Desvio_Std	0.31022827
17	complejidad_provincia_IQR	0.19610411
18	complejidad_provincia_Min	-1.33322010
19	complejidad_provincia_Max	0.08786897
20	n_Media	8519.00000000
21	n_Mediana	8519.00000000
22	n_Desvio_Std	NA
23	n_IQR	0.00000000
24	n_Min	8519.00000000
25	n_Max	8519.00000000

4. Test ANOVA

Centralidad por Sección

- Verificación de supuestos
 - Test de Levene (Homogeneidad de Varianzas)
- Modelo Ajustado
 - Test de Welch (Robusto ante Heterogeneidad)
- Análisis Post-Hoc
 - Test de Games-Howell (Visualización)

4. Test de Levene (Homogeneidad de Varianzas)

Objeto de estudio --> **CENTRALIDAD x SECCION**

$$H_0: \sigma_1^2 = \sigma_2^2 = \sigma_3^2 = \dots = \sigma_k^2$$

H_1 : Al menos una de las varianzas poblacionales es diferente

Regla de decisión

Si p-valor < 0.05: Rechazo H_0 -> Varianza NO es homogénea

Si p-valor >= 0.05: NO rechazo H_0 -> Varianza es homogénea

```
--- TEST DE LEVENE (Homogeneidad de Varianzas) ---
> print(Levene_test_resultado)
Levene's Test for Homogeneity of Variance (center = median)
  Df F value    Pr(>F)
group     8  9.3721 0.0000000000005734 ***
               8470
---
signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```



Se **rechazó H_0** (varianzas no homogéneas).

Considerar **ANOVA de Welch**
(Alternativa robusta a heterogeneidad)

4. Modelo Ajustado (Test Welch)

Objeto de estudio --> **CENTRALIDAD x SECCION**

$$H_0: \sigma_1^2 = \sigma_2^2 = \sigma_3^2 = \dots = \sigma_k^2$$

H_1 : Al menos una de las varianzas poblacionales es diferente

--- ANOVA DE WELCH (Robusto ante heterogeneidad) ---

```
one-way analysis of means (not assuming equal variances)

data: centralidad and seccion_f
F = 198.19, num df = 8.0, denom df = 1446.1, p-value <
0.000000000000022
```

Regla de decisión

Si p-valor < 0.05: **Rechazo H₀** -> hay una **diferencia estadísticamente significativa** entre las medias de los grupos

Si p-valor >= 0.05: NO rechazo H₀ -> No hay evidencia suficiente para rechazar H₀.

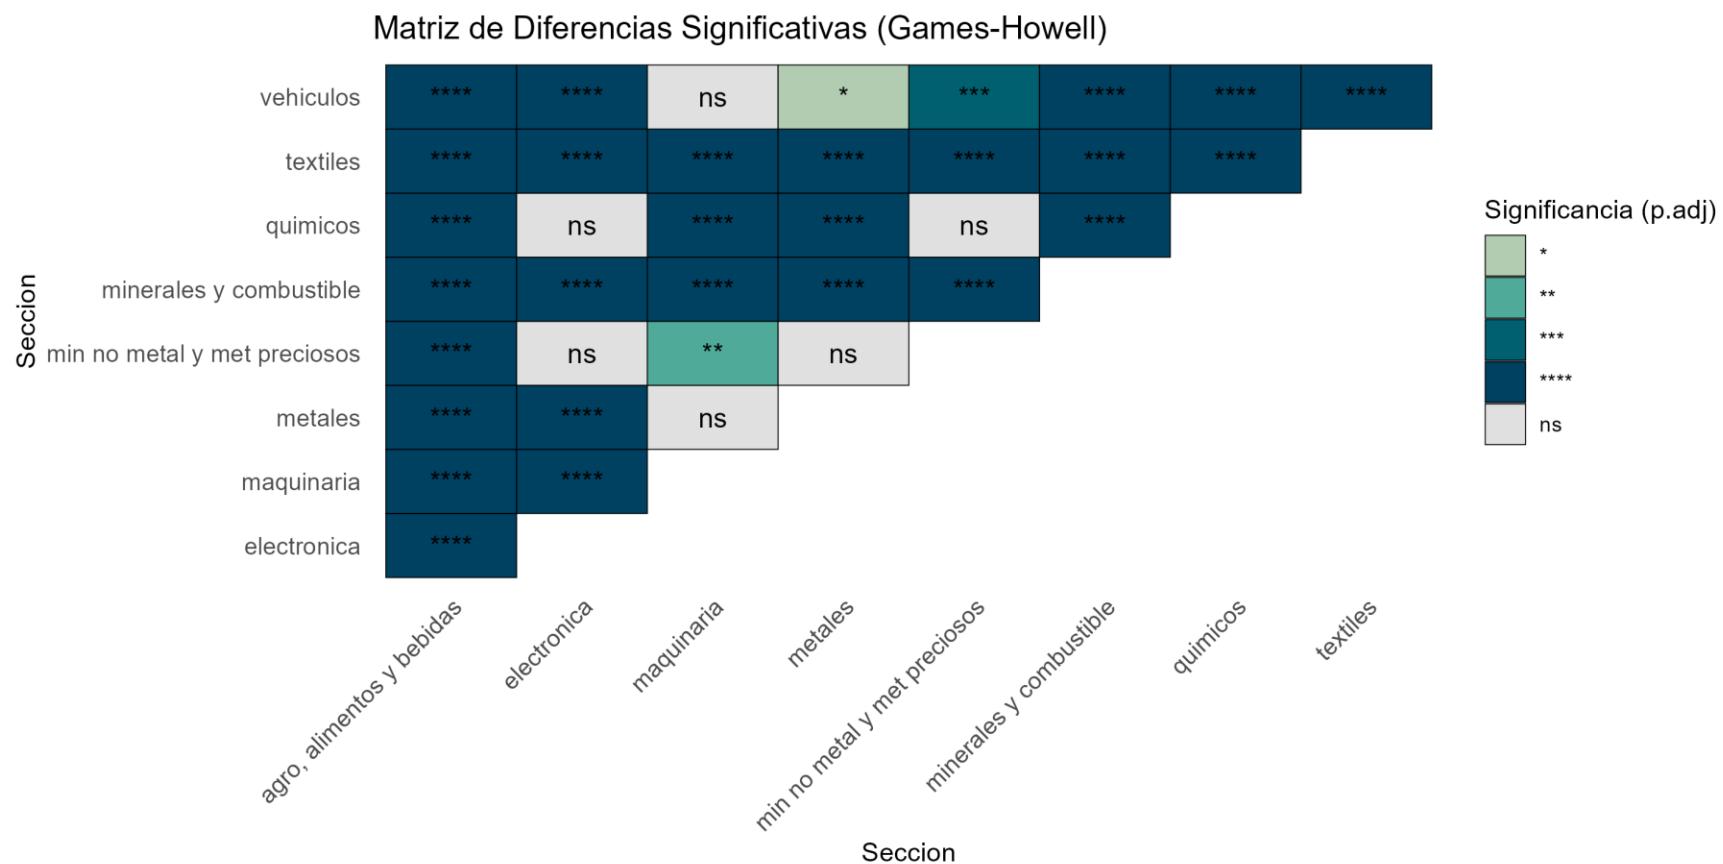


Se **rechazó H₀** (Existe diferencia significativa en Centralidad por Sector).

Avanzamos con análisis post_hoc para cuantificar y visualizar los resultados.

4. Análisis Post-Hoc (Games-Howell)

Objeto de estudio --> **CENTRALIDAD x SECCION**



5. Test de Hipótesis

Modelo de Regresión Lineal Múltiple

- Hipótesis: Presentación de Modelo
 - Método de Mínimos Cuadrados Ordinarios
- Verificación de supuestos
 - Multicolinealidad
 - Heterocedasticidad
- Resultados y Visualización

5. Modelo de Regresión Lineal (MCO)

Objeto de estudio --> POTENCIALIDAD

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + C_1 + C_2$$

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 X_1 + \hat{\beta}_2 X_2 + \hat{\alpha}_1 C_1 + \hat{\alpha}_2 C_2 + \mu$$

```
# HIPÓTESIS C:  
# Y = Potencialidad (Winsorizada)  
# X1 = Complejidad Producto (winsorizada)  
# X2 = Distancia  
# Control 1 = Tamaño de Mercado (Log FOB Mundial)  
# Control 2 = Sector (sección)
```

Método de Mínimos Cuadrados Ordinarios



Verificación de supuestos



```
--- RESUMEN PRELIMINAR (MCO Clásico) ---  
> print(summary(modelo_c))  
  
Call:  
lm(formula = formula_hipotesis_c, data = df_pot_transf)  
  
Residuals:  
    Min      1Q  Median      3Q     Max  
-0.36219 -0.06361 -0.00462  0.05692  0.76110  
  
Coefficients:  
              Estimate Std. Error t value Pr(>|t|)  
(Intercept) -0.13428217  0.01883833 -7.128   0.00000000000102  
complejidad_producto_win  0.19993145  0.00032551 614.208 < 0.0000000000000002  
distancia     0.18760488  0.01898665  9.881 < 0.0000000000000002  
log_fob_mundial -0.00306745  0.00013243 -23.162 < 0.0000000000000002  
seccionelectronica  0.00007245  0.00134451  0.054   0.95702  
seccionmaquinaria  0.03116950  0.00094874 32.853 < 0.0000000000000002  
seccionmetales    0.00684403  0.00100697  6.797   0.00000000001075  
seccionmin no metal y met preciosos  0.00429619  0.00147316  2.916   0.00354  
seccionminerales y combustible  0.04560105  0.00167337 27.251 < 0.0000000000000002  
seccionquimicos   0.01530612  0.00086073 17.783 < 0.0000000000000002  
sectiontextiles   -0.06885337  0.00082887 -83.069 < 0.0000000000000002  
seccionvehiculos  0.02828681  0.00172120 16.434 < 0.0000000000000002
```

```
(Intercept) ***  
complejidad_producto_win ***  
distancia ***  
log_fob_mundial ***  
seccionelectronica ***  
seccionmaquinaria ***  
seccionmetales ***  
seccionmin no metal y met preciosos **  
seccionminerales y combustible ***  
seccionquimicos ***  
sectiontextiles ***  
seccionvehiculos ***  
---  
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1  
  
Residual standard error: 0.09201 on 127254 degrees of freedom  
Multiple R-squared:  0.8392, Adjusted R-squared:  0.8392  
F-statistic: 6.037e+04 on 11 and 127254 DF, p-value: < 0.0000000000000002
```

5. Supuestos: Multicolinealidad y Heterocedasticidad

Objeto de estudio --> **POTENCIALIDAD**

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + C_1 + C_2$$

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X_1 + \hat{\beta}_2 X_2 + \hat{C}_1 C_1 + \hat{C}_2 C_2 + \mu$$

```
# HIPÓTESIS C:  
# Y = Potencialidad (winsorizada)  
# X1 = Complejidad Producto (winsorizada)  
# X2 = Distancia  
# Control 1 = Tamaño de Mercado (Log FOB Mundial)  
# Control 2 = Sector (sección)
```

Ajuste con Test White y test t para cada variable (Ver tabla)

CONFIRMA H1: A mayor complejidad, mayor potencialidad.

HALLAZGO (CONTRA-INTUITIVO): Relación POSITIVA y SIGNIFICATIVA.
Interpretación: Los productos con mayor potencial estratégico son los más 'lejanos'.

Multicolinealidad

Control vía: DIAGNÓSTICO VIF (Factor de Inflación de Varianza)

complejidad_producto_win	distancia	log_fob_mundial
1. 519290	1. 022990	1. 095799
seccion		
1. 648143		

Multicolinealidad bajo control.

Heterocedasticidad

Control vía: Test de Breusch-Pagan

```
--- TEST DE BREUSCH-PAGAN ---  
> print(bp_test)  
  
studentized Breusch-Pagan test  
  
data: modelo_c  
BP = 11852, df = 11, p-value < 0.000000000000022
```

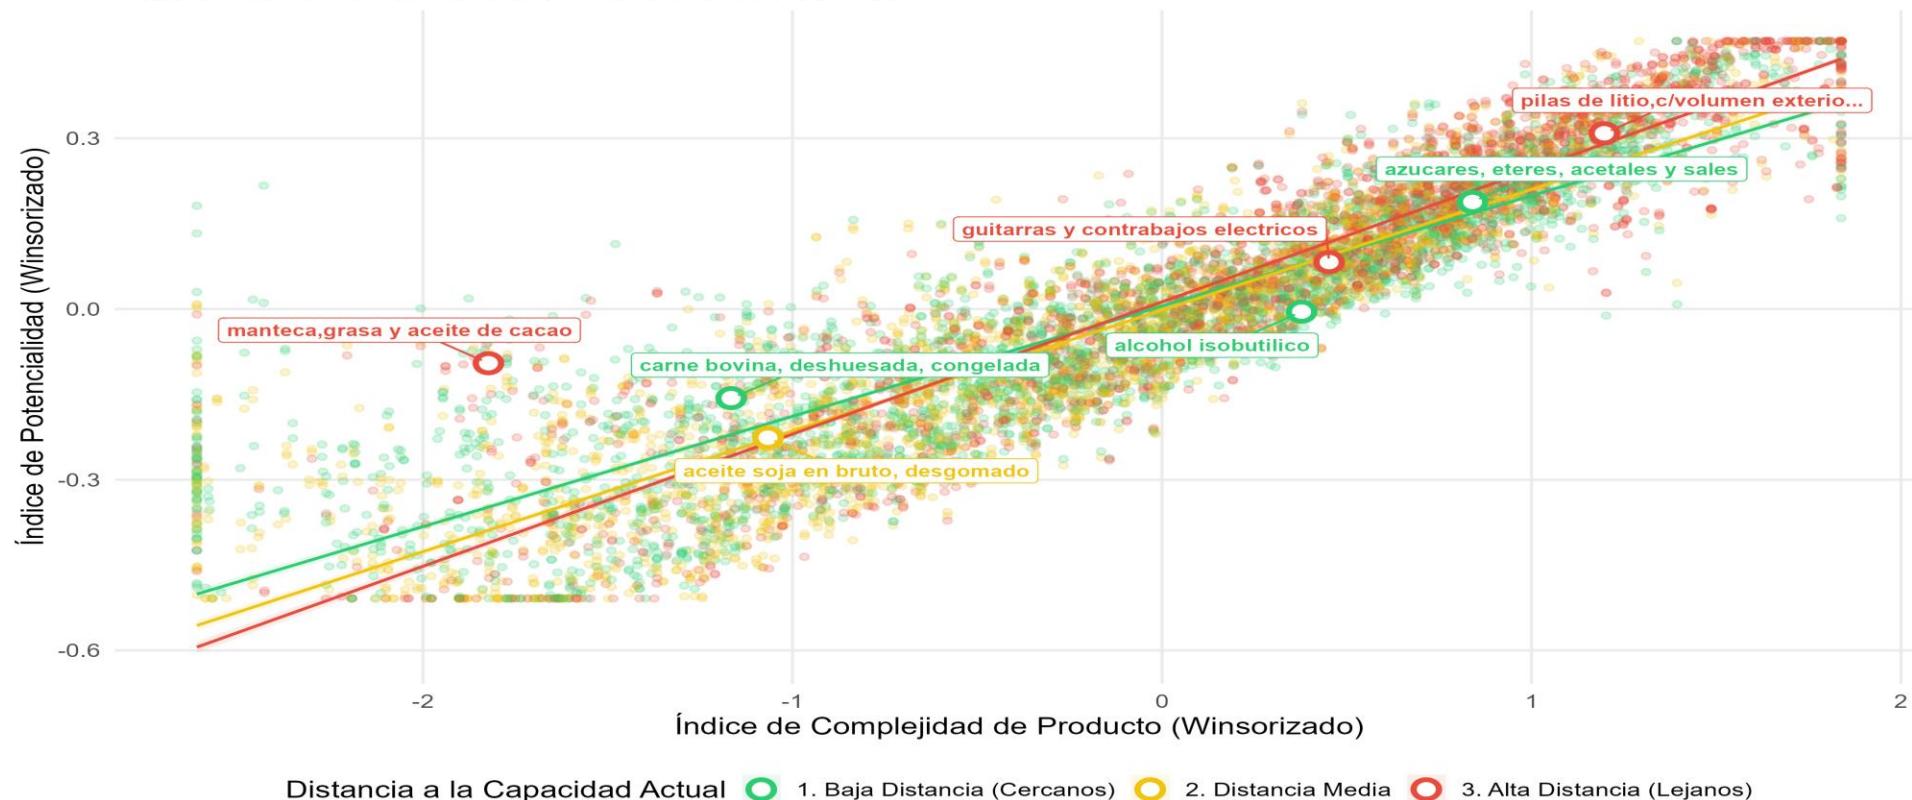
Se rechaza H0: Heterocedasticidad detectada.

CORRECCIÓN: Se utilizarán Errores Estándar Robustos (HC1) para la inferencia final.

5. Modelo de Regresión Lineal

Complejidad y Distancia: Motores de la Diversificación Productiva

Relación entre el valor de un producto (Complejidad) y la oportunidad que genera (Potencialidad), segmentada por la dificultad para alcanzarlo (Distancia).



Nota: La pendiente positiva confirma que la complejidad impulsa el potencial. La separación de las líneas confirma el hallazgo de la regresión: los productos 'Lejanos' tienen mayor potencial para el mismo nivel de complejidad.

6. Conclusiones

- Nuestros resultados **refutan** la hipótesis de que la "**lejanía productiva**" disminuye el valor de la oportunidad; por el contrario, la evidencia sugiere que la ganancia de **oportunidad estratégica** (*opportunity gain*) es una **función creciente de la distancia** a recorrer.
- El modelo econométrico planteado demuestra que la estructura de incentivos de la diversificación provincial presenta un **trade-off**: mientras que la complejidad garantiza valor agregado, las oportunidades de **mayor potencial** no se encuentran en la "zona de confort" de la baja distancia productiva, sino que **requieren saltos de capacidades significativos**.
- En pos de pensar un **desarrollo potencial** y la estructura de oportunidades actuales de cada provincia, resulta fundamental revisar las **posibilidades y estrategias**, y sus consecuentes **riesgos**. La política económica, debe **evitar fórmulas únicas**. En cambio, se vuelve crucial que cada provincia desarrolle una **hoja de ruta estratégica** basada en la **maximización de su propia función de opportunity gain** revelada. El análisis de complejidad debe ser la base para diseñar **paquetes de incentivos a medida** que promuevan los saltos específicos necesarios para su estructura productiva.

7. Futuras Lineas de Investigación

- Los resultados actuales, como el **trade-off entre Potencialidad y Distancia**, requieren una validación y profundización, especialmente en lo que respecta a la **inferencia causal**, que es inherentemente limitada en un análisis de corte transversal
- Incorporación de la **Dimensión Temporal (Datos de Panel)**: La estructura de corte transversal actual nos limita a observar las oportunidades en un solo punto en el tiempo. El análisis ganaría un valor sustancial si se migrara a una estructura donde se pudieran **observar las mismas provincias a lo largo del tiempo**. En esta línea, se podría realizar un análisis de **trayectorias de diversificación** estudiando cómo la Potencialidad (o la Centralidad) cambian en el tiempo. Esto permitiría estimar la Propensión de Largo Plazo (PLP) de la complejidad o distancia en el tiempo.
- Por último, se podría efectuar una **expansión del ANOVA y Comparaciones Múltiples**

El hallazgo de diferencias significativas en la centralidad por sección justifica un análisis más detallado Un ANOVA de Dos Factores (Two-Way ANOVA) podría ser utilizado para un análisis más exhaustivo incluyendo otra variable categórica de interés, como la Región Geográfica (considerando que provincia es una variable categórica disponible), y evaluar la interacción entre sección y region. Esto respondería a la pregunta: "¿Varía el efecto sectorial (sección) sobre la centralidad según la región de la provincia?"